

PROPUESTA DE PROYECTO

Reconocedor y Analizador de Voz en Python

Marcelo Lara, Ian Cuevas, Luca Galaz

18 de agosto de 2026

1. Descripción del Proyecto

El objetivo de este proyecto es desarrollar una herramienta en Python capaz de procesar una muestra de voz (grabada en tiempo real o cargada desde un archivo de audio) y estimar automáticamente un conjunto de características del hablante: perfil demográfico (género, edad y acento), estado físico y hábitos (signos asociados a tabaquismo, fatiga o irregularidades respiratorias) y estado emocional (nivel de estrés y emoción predominante).

El enfoque se basa en integrar herramientas de análisis acústico con modelos preentrenados de aprendizaje profundo. De este modo, combinamos mediciones físicas directas de la señal con las predicciones de redes neuronales, lo que permite contrastar ambos resultados y verificar la coherencia de los datos obtenidos.

2. Variables y Características a Analizar

Las características a extraer se dividen en tres áreas principales:

■ Perfil y Demografía:

- Género y edad estimada.
- Nacionalidad o acento regional.

■ Estado Físico y Hábitos:

- Hábito de fumar.
- Fatiga o somnolencia.
- Indicadores fisiológicos y respiratorios.

■ Estado Emocional:

- Nivel de estrés.
- Emoción predominante.

3. Librerías y Herramientas a Utilizar

Para la implementación del sistema se utilizarán los siguientes entornos y librerías de código abierto:

praat-parselmouth: Interfaz en Python para el motor del software acústico **Praat**. Permite obtener mediciones físicas de la señal: tono base (F_0), formantes vocálicos y parámetros de perturbación periódica (*Jitter* y *Shimmer*).

openSMILE: Extractor estándar de características de audio para análisis paralingüístico. Procesa conjuntos de descriptores sobre energía, sonoridad y dinámica temporal útiles para cuantificar fatiga y estrés.

SpeechBrain: Marco de trabajo basado en PyTorch para procesamiento del habla. Facilita el uso de modelos listos para inferencia en clasificación de emociones y detección de acentos.

transformers (Hugging Face): Ecosistema para la ejecución de modelos de aprendizaje profundo. Se utilizará para correr redes neuronales preentrenadas sobre representaciones acústicas (*Wav2Vec 2.0*) para la estimación de edad y género.

Gradio / Streamlit: Marcos de desarrollo para interfaces web en Python. Permitirán desplegar una interfaz gráfica interactiva con controles de grabación, carga de archivos y visualización de espectrogramas y resultados.

4. Flujo de Trabajo del Sistema

El procesamiento del audio se estructura en cinco etapas:

Paso 1: Captura y Acondicionamiento del Audio: Se ingresa el audio mediante un archivo *.wav* o grabación directa desde el micrófono. Se normaliza la señal y se recortan los silencios para analizar únicamente los tramos de voz activa.

Paso 2: Extracción de Parámetros Físicos: A través de *Parselmouth* y *openSMILE* se calculan las métricas acústicas de base: distribución del tono, estabilidad de la onda y niveles de energía.

Paso 3: Inferencia con Modelos de IA: La señal acondicionada se procesa en paralelo mediante los clasificadores de *Hugging Face* y *SpeechBrain* para obtener estimaciones de edad, género, emoción y acento.

Paso 4: Cruce y Validación de Resultados: Un módulo en Python compara las predicciones de los modelos con las métricas físicas extraídas (por ejemplo, validando si el género predicho concuerda con el rango de F_0 medido). A partir de esta comparación se asigna un porcentaje de confianza y se señalan posibles discrepancias.

Paso 5: Visualización y Reporte: La interfaz gráfica presenta el espectrograma del audio junto con un panel que resume el perfil demográfico, el estado estimado del usuario y el nivel de fiabilidad del análisis.

5. Referencias y Repositorios

- Parselmouth (Praat en Python): <https://github.com/YannickJadoul/Parselmouth>
- openSMILE (audEERING): <https://github.com/audeering/opensmile>
- SpeechBrain: <https://github.com/speechbrain/speechbrain>
- Hugging Face Transformers: <https://github.com/huggingface/transformers>
- Documentación Wav2Vec 2.0 (Hugging Face): https://huggingface.co/docs/transformers/model_doc/wav2vec2
- Gradio UI: <https://github.com/gradio-app/gradio>
- Streamlit: <https://github.com/streamlit/streamlit>
- Software Praat: <https://www.fon.hum.uva.nl/praat/>