

PROPUESTA DE PROYECTO

Reconocedor y Analizador Múltiple de Voz en Python

Ramo: Acústica Computacional

13 de agosto de 2026

1. ¿De qué trata la idea?

La idea es armar un programa en Python que reciba un archivo de audio (o la voz grabada desde el micrófono) y extraiga automáticamente un conjunto de características de la persona: género, edad estimada, nacionalidad o acento, si fuma, cansancio, nivel de estrés, emoción principal y signos de condiciones respiratorias o neurológicas.

Para no reinventar la rueda ni ponernos a programar algoritmos complejos desde cero, el proyecto consiste en conectar librerías y modelos ya existentes en un solo *pipeline* de software híbrido. Usaremos herramientas de acústica tradicional para sacar métricas físicas de la onda y modelos de aprendizaje profundo (*Deep Learning*) para las clasificaciones, cruzando ambos resultados para validar las predicciones.

2. Características a detectar

Las características seleccionadas se organizan en tres grupos simples:

■ Perfil y Demografía:

- **Género y Edad Estimada:** Se determinan según qué tan aguda o grave es la voz (F_0) y el uso de modelos preentrenados.
- **Nacionalidad o Acento Regional:** Se identifican detectando patrones de pronunciación e intonación con modelos de reconocimiento de idioma.

■ Estado Físico y Hábitos:

- **Hábito de Fumar:** El consumo de tabaco cambia la textura de la voz, generando ligeras variaciones de ruido en la onda fónica.
- **Cansancio o Somnolencia:** Al estar fatigados se suele hablar más lento, con menor volumen y un tono más plano.
- **Condiciones Respiratorias o Neurológicas:** Se buscan micro-temblores o pausas anormales para tomar aire.

■ Estado Mental y Emocional:

- **Nivel de Estrés:** La tensión muscular al estar estresado cambia la variación del tono al hablar.
- **Emoción Principal:** Clasificación de emociones (alegría, tristeza, ira, etc.) según velocidad, volumen y tono.

3. Repositorios y Librerías

Reutilizaremos este conjunto de herramientas según lo que necesitemos resolver:

praat-parselmouth: Binding de Python para el motor del software **Praat**.

- **Para qué sirve:** Nos da los datos físicos de la onda. Mide el tono base (F_0 , grave o agudo), resonancias de la voz (formantes) y qué tan limpia está la señal (*Jitter* y *Shimmer*).

openSMILE: Extractor automático de características de audio.

- **Para qué sirve:** Devuelve una tabla de métricas sobre la energía y ritmo de la voz. Sirve para evaluar el cansancio, estrés o indicadores físicos.

SpeechBrain: Librería de PyTorch lista para usar.

- **Para qué sirve:** Incluye modelos preentrenados para clasificar emociones y reconocer el acento o nacionalidad.

transformers (Hugging Face): Repositorio de modelos de inteligencia artificial.

- **Para qué sirve:** Permite usar redes neuronales preentrenadas (*Wav2Vec 2.0*) que predicen edad y género directamente desde el audio.

Gradio / Streamlit: Marcos para interfaces web en Python.

- **Para qué sirve:** Permite armar una interfaz sencilla con un botón de grabación y paneles para mostrar los resultados e imágenes del espectrograma.

4. Flujo del Sistema (Paso a Paso)

El sistema procesará el audio en 5 pasos sencillos:

Paso 1: Capturar y Limpiar el Audio: Se graba desde el micrófono o se carga un archivo `.wav`. Se recortan los silencios para procesar solo cuando la persona habla.

Paso 2: Extracción Acústica Física: Usamos **Parselmouth** y **openSMILE** para medir el tono, la estabilidad de la onda y la energía fónica (útil para detectar cansancio, estrés o hábito de fumar).

Paso 3: Inferencia con IA: Pasamos el audio por los modelos preentrenados de Hugging Face y **SpeechBrain** para estimar edad, género, emoción y acento.

Paso 4: Cruce, Validación y Consolidación (Motor Híbrido): Un script en Python toma las mediciones físicas del Paso 2 y las predicciones de la IA del Paso 3 para realizar un análisis cruzado:

- **Validación Física:** Compara la predicción de la IA con los datos reales de la onda (por ejemplo, verifica si el género asignado coincide con el tono fundamental F_0 medido).

- **Detección de Discrepancias:** Asigna un grado de confianza al resultado y genera alertas si la física del sonido contradice la respuesta de la IA.
- **Estructuración:** Reúne el diagnóstico validado y las reglas de hábitos en un solo paquete de datos.

Paso 5: Visualización: La interfaz (**Gradio**) despliega el espectrograma de la onda fónica, las tarjetas con los resultados validados y el nivel de confianza del análisis.